

Prédiction d'évènements de retard dans le trafic aérien: Une évaluation de Modèles d'Apprentissage .

Khadija Maaroufi , Meryem Kada , Hajar Slimani
Filière ILIA , Ecole nationale de sciences appliquées, Fes

Résumé —Ce projet est basé sur la prévision du retard des vols en s'appuyant sur plusieurs facteurs notamment les compagnies aériennes, les aéroports et les facteurs climatiques.

L'analyse comporte deux volets : une classification visant à déterminer si les vols présentent un retard supérieur au seuil défini et une régression pour déterminer le temps exact du retard.

Plusieurs algorithmes de l'intelligence artificielle ont été testés afin de sélectionner ceux qui donnent les meilleures performances pour chaque tâche (régression, classification).

Les résultats obtenus montrent une bonne capacité des modèles choisis à détecter les retards et estimer leurs durées .

I. INTRODUCTION

Le transport aérien joue un rôle important et essentiel dans l'économie mondiale en gérant chaque année un très grand nombre de passagers ainsi que d'importants volumes de marchandises .

Or cette industrie affronte un défi majeur : **Retard des vols**.

Ce problème engendre des conséquences financières et opérationnelles pour les compagnies et les passagers .Selon les estimations , les retards coûtent des milliards de dollars annuellement en frais opérationnels supplémentaires compensations financières et perte de productivité .

Face à cette problématique , l'usage d'apprentissage automatique reste une solution intéressante pour anticiper et limiter ces conséquences . le fait d'avoir la possibilité de prédire le retard des vols permettra aux compagnies de mieux s'organiser , informer les passagers à l'avance .

Ce projet est divisé en deux blocs principaux pour traiter ce problème . Le premier consiste à construire un modèle de classification capable d'indiquer si un vol dépassera un retard de 15min ,seuil critique à partir duquel les perturbations deviennent significatives .Le deuxième vise à estimer la durée précise de retard en min.

En se basant sur les données historiques et les modèles d'apprentissage automatique , ce travail a pour but de contribuer à une meilleure ponctualité des vols et d'améliorer l'expérience des passagers .

II. FORMULATION DU PROBLEME

le retard d'un vol peut être influencé par de nombreux facteurs opérationnels et environnementaux, ce qui rend sa prédiction complexe. Dans ce travail, le problème est formulé à partir de données historiques comprenant différentes caractéristiques telles que la compagnie aérienne, l'aéroport de départ, l'horaire prévu, la durée du vol ou encore les conditions météorologiques.

L'objectif est d'étudier deux aspects complémentaires du phénomène :

classification binaire : déterminer si un vol dépassera un retard de 15 minutes.

Cette tâche consiste à prédire une variable cible prenant deux valeurs :

- 0 : vol à l'heure ou avec un retard inférieur à 15 minutes
- 1 : vol retardé de plus de 15 minutes

Régression supervisée : estimer la durée exacte du retard en minutes.

Cette tâche vise à prédire une variable continue représentant le nombre de minutes de retard.

Ainsi, le problème est formalisé comme une combinaison de classification et de régression, permettant à la fois d'identifier les vols susceptibles d'être retardés et d'estimer l'ampleur du retard.

Travaux antérieurs sur la prédiction du retard des vols

[1] En 2021, Kaur, Koundal et Banerjee ont prédit les retards binaires en utilisant des données proches de celles du Département des Transports américain. Après avoir testé plusieurs modèles (régression logistique, KNN, Naïve Bayes, SVM, arbres, Random Forest), le **Random Forest** a obtenu les meilleures performances avec **92 % de précision** et un **F1-score de 0,91**.

[2] En 2020, Rebollo et Balakrishnan ont étudié la prédiction du retard en minutes sur une large base de données nationale. Parmi les modèles évalués c'est le **LSTM** qui a donné le meilleur résultat, avec une **RMSE de 12,8 minutes**.

III. MATERIEL ET METHODES

1. Acquisition des données

Dans ce projet , nous avons travaillé sur le [3] dataset *Airline Delay Data* qui est disponible sur la plateforme Mendeley Data.

Cet ensemble de données provient de différentes sources, notamment :le Bureau of Transportation Statistics(BTS) qui fournis la majeure partie des données du dataset avec près de 1.2 million vols documentés, puis, on a FAA ou Federal Aviation Administration qui donnent des informations précises sur la capacité exacte de chaque avion , et finalement, les données météorologique provenant du National Centre of Environment qui nous permettent d'évaluer et quantifier l'impact des conditions climatiques sur le retard.

2. Analyse de données exploratoires

La qualité des données constitue un concept fondamental dans tout projet de Machine Learning. En effet, selon le principe bien connu *Garbage In, Garbage Out*, des données d'entrée incomplètes, incohérentes ou bruitées conduiront inévitablement à des résultats peu fiables, quel que soit le modèle utilisé. C'est pour cette raison qu'une analyse exploratoire approfondie s'impose avant toute modélisation. Cette étape permet non seulement d'obtenir une vision globale du dataset mais aussi d'identifier ses forces comme ses faiblesses. Elle inclut notamment :

i. Audit initial des données

L'audit initial a pour objectif d'évaluer la structure, la qualité et l'intégrité du dataset avant tout traitement. Cette phase cruciale permet d'identifier les problèmes potentiels et d'établir une baseline pour les transformations ultérieures. L'analyse a été réalisée à l'aide d'outils Python standard (Pandas, NumPy et matplotlib) suivant une méthodologie systématique en cinq étapes.

- **Analyse dimensionnelle** : Le dataset est composé de 1,201,664 enregistrements de vols décrits par 61 variables.

- **Typologie des variables** : L'examen des types de données montre L'analyse révèle une diversité typologique marquée avec 20 variables numériques (32.8%), 6 catégorielles (9.8%), 6 temporelles (9.8%) et 29 booléennes (47.5%). Cette hétérogénéité nécessite des stratégies de prétraitement adaptées, notamment pour les variables catégorielles à haute cardinalité qui exigent des techniques d'encodage spécifiques.

ii. L'analyse de complétude : Évaluation du taux de valeurs manquantes par variable

Dans notre dataset, on constate la présence de 5 colonnes avec valeurs manquantes :

Variable	Valeurs manquantes
arrdelay	3206
temperature	460
windspeed	460
windspeedsquare	460
windgustspeed	460

Donc, le taux des variables manquantes est 0.27% pour la variable **arrdelay** qui représente la variable cible et 0.04% pour les variables météorologiques (temperature,windspeed,etc.)

iii. l'analyse de Distribution

L'étude des distributions statistiques a permis de caractériser la variabilité des données et d'identifier les besoins de transformation.

Pour les variables binaires :

Variable	Skewness	Interprétation	Taux d'événements estimé
snowdummy	13.68	Classe 1 très rare	~0.1%
snowtracedummy	9.72	Classe 1 rare	~0.2%
raintracedummy	3.67	Classe 1 peu fréquente	~3–5%
raindummy	3.12	Classe 1 minoritaire	~5–8%
windgustdummy	1.16	Classe 1 minoritaire modérée	~20–30%

Pour les variables continues :

Variable	Skewness	Interprétation	Traitement
depdelay	7.06	Asymétrie positive extrême	Transformation logarithmique
arrdelay	5.95	Asymétrie positive extrême	Transformation logarithmique
temp_40_infty	17.22	Événement très rare Temp > 40°C exceptionnel	Regroupement : extreme_heat = max(temp_30_40, temp_40_infty)
temp_ninfty_n10	10.67	Événement très rare Temp < -10°C exceptionnel	Regroupement : extreme_cold = max(temp_ninfty_n10, temp_n10_0)

iv. Analyse de corrélation :

L'analyse des coefficients de corrélation de Pearson avec la variable cible **depdelay** met en évidence une hiérarchie d'influence. La relation quasi-parfaite entre retards départ et arrivée ($r = 0.932$) confirme la propagation systématique des retards, les variables météorologiques (pluie, neige, vent) présentent des corrélations modérées mais statistiquement significatives (0.032 à 0.111), validant leur inclusion dans le modèle. Les identifiants opérationnels (tailnum, dest, Origin) montrent des corrélations surprenamment élevées (0.056 à 0.109), suggérant des patterns récurrents spécifiques à certains avions, destinations ou origines. En revanche, les variables économiques (PIB par habitant) et certaines caractéristiques de vol (distance, capacité) présentent des corrélations minimales (-0.024 à 0.001), nécessitant potentiellement des transformations non-linéaires ou des interactions pour révéler leur pouvoir prédictif.

3. Nettoyage et préparation des données

Après avoir exploré et obtenu une vue d'ensemble sur notre dataset, en identifiant ses caractéristiques et ses problèmes et en examinant les données, on va passer maintenant au nettoyage qui est une étape primordiale dans le pipeline d'un projet de machine Learning qui permet de corriger les données dupliquées, inexactes et incohérentes susceptibles de fausser les résultats et de conduire à des conclusions erronées.

Le nettoyage des données comporte plusieurs étapes, chacune répondant à des défis spécifiques liés à la qualité, à la structure et à la pertinence des données.

1. Traitement des valeurs manquantes

Comme nous avons cité précédemment que notre dataset contient à peu près 0.3% des valeurs manquantes et puisque les données sont comme une matière brute sur laquelle repose tout processus d'apprentissage donc on ne va pas les supprimer mais plutôt on va les imputer avec la médiane car elles contiennent des valeurs aberrantes.

2. Suppression des doublons

Pour garantir que les données de notre dataset soient uniques et pertinents, une suppression des valeurs dupliquées constitue donc une étape essentielle qui va assurer non seulement que chaque observation va apporter une nouvelle information mais aussi que le modèle ne va pas être biaisé, chose qui va améliorer la fiabilité et la précision de ce dernier.

iii. Correction des formats incohérents

L'analyse de la typologie des différentes variables du dataset a montré que la colonne `scheduleddeparturedatetime` qui représente la date et l'heure programmées du décollage est stockée sous le format `Object` donc une conversion en type `datetime` est obligatoire afin de pouvoir extraire des nouvelles informations notamment : l'année, le mois, le jour ou encore l'heure de la journée.

Par ailleurs, on a constaté la présence des variables binaires avec un pourcentage (47.5%) ce qui oblige à s'assurer que ces colonnes contiennent uniquement des valeurs 0 et 1.

iv. Encodage des variables catégorielles

Étant donné que la plupart des modèles présents aujourd'hui fonctionnent avec des données numériques, l'encodage des variables catégorielles s'impose. Parmi les différentes stratégies de l'encodage nous avons opté pour `target encoding` qui remplace chaque catégorie par la moyenne de la variable cible observée pour cette modalité.

v. Ingénierie des caractéristiques

C'est un processus qui vise à créer des caractéristiques significatives à partir des variables existantes afin d'améliorer les performances de nos modèles.

Dans cette optique nous avons décidé d'appliquer des changements à notre dataset à titre d'exemple :

-la création de la caractéristique `is_weekend` :

Cette variable binaire permet de distinguer entre les vols du week-end de ceux au sein de la semaine. Cette distinction est pertinente car les opérations aériennes, la densité du trafic et les causes de retard diffèrent souvent entre ces deux périodes.

-création de la caractéristique `is_holiday` :

À l'instar de la caractéristique `is_weekend`, cette variable binaire identifie les périodes de vacances massives connues pour perturber les opérations aériennes notamment : la fin de décembre et le début de janvier connus par les fêtes de Noël et du nouvel an et les mois des vacances d'été de juin à août.

Cette variable permet de capturer l'impact des pics saisonniers sur la ponctualité des vols.

-Consolidation des variables hiérarchiques : Afin d'éviter la présence de seize colonnes binaires décrivant la taille des hubs aéroportuaires et des compagnies aériennes, nous les avons fusionnées en quatre variables catégorielles ordinales (une par dimension : origine aéroport, destination aéroport, compagnie origine, compagnie destination). Chaque variable traduit les quatre niveaux hiérarchiques présents (1: non-hub, 2: petit hub, 3: hub moyen, 4: grand hub), cette approche permet non seulement de préserver la relation d'ordre mais aussi de réduire considérablement la dimensionnalité et améliorer l'interprétabilité du modèle.

vi. Sélection des caractéristiques

C'est un processus qui vise à choisir un ensemble de variables les plus pertinentes du dataset tout en éliminant celles qui n'apportent aucune valeur ajoutée significative.

Dans notre analyse, nous avons pris la décision de supprimer les variables de température (`temperature`, `temp_ninety_n10`, `temp_n10_0`, `temp_0_10`, etc.) du jeu de données final. Cette décision s'appuie sur plusieurs constats notamment : la **corrélation faible** avec la variable cible (`arrdelay`), comme observé lors de l'analyse exploratoire, la **redondance partielle** avec d'autres indicateurs météorologiques plus discriminants finalement la **complexité ajoutée** sans gain prédictif substantiel.

Après l'élimination des variables de température, nous avons appliqué un seuil de corrélation à l'ensemble des caractéristiques restantes. Seules les variables présentant un coefficient de corrélation de Pearson supérieur à 0.05 avec la variable cible (`arrdelay`) ont été conservées pour la modélisation. Ce filtre statistique permet d'identifier et de retenir uniquement les prédicteurs ayant une relation significative avec les retards.

III. METHODOLOGIE

1. Formules mathématiques

i. Régression

La prédiction de retard des vols consiste un enjeu majeur pour l'optimisation des opérations aériennes et l'amélioration de l'expérience de l'utilisateur .

Au cours de cette étude , nous représentons la prédiction de retard des vols sous la forme d'une problématique de la régression supervisée dont le but est de déterminer une fonction continue :

$$f : X \in \mathbb{R}^d \rightarrow y \in \mathbb{R}$$

Où X représente le vecteur des variables explicatives et y le retard à l'arrivée en minutes.

Dans un problème de régression , on cherche a trouver les meilleurs paramètres en minimisant la fonction de perte quadratique .

$$\theta^* = \arg \min_{\theta} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Dans ce cadre, la qualité des prédictions est évaluée via :

MAE (Mean Absolute Error) :

$$MAE = \frac{1}{n} \sum |y - \hat{y}|$$

RMSE (Root Mean Squared Error)

$$RMSE = \sqrt{\frac{1}{n} \sum (y - \hat{y})^2}$$

R² (Coefficient de détermination) :

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

ii. Classification

La prédiction de retard des vols constitue un enjeu majeur pour l'optimisation des opérations aériennes et l'amélioration de l'expérience utilisateur.

Au cours de cette étude, nous avons formulé la prédiction de retard des vols sous la forme d'une problématique de classification supervisée binaire. L'objectif est de déterminer une fonction de décision discrète qui attribue à chaque vol une étiquette de classe :

$$f : X \in \mathbb{R}^d \rightarrow y \in \{0, 1\}$$

Les métriques d'évaluations utilisées sont :

Accuracy : Proportion de prédictions correctes (positives et négatives) parmi toutes les observations.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Precision : Proportion de prédictions positives qui sont réellement correctes.

$$Precision = \frac{TP}{TP + FP}$$

Recall: Capacité du modèle à détecter tous les exemples positifs (événements réellement présents).

$$Recall = \frac{TP}{TP + FN}$$

F1-Score : Moyenne harmonique de la précision et du rappel, équilibre entre les deux.

$$F1-Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

ROC-AUC (Aire sous la courbe ROC) : Mesure la qualité globale de la séparation entre classes positives et négatives, indépendamment du seuil choisi.

Avec TP = Vrais Positifs, TN = Vrais Négatifs

FP = Faux Positifs, FN = Faux Négatifs

2. Les modèles testés :

Régression Linéaire

La régression lineaire est l'un des piliers essentiels dans l'apprentissage statistique , il s'appuie sur l'hypothèse de trouver une relation entre la variable cibles et les variables explicatives ,

Le modele représente les prédictions avec l'équation :

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_d x_d$$

c'est un modele interpretable , peu couteux , utiliser comme baseline .

1. K-Nearest Neighbors (KNN)

le KNN est un algorithme non paramétrique , se base sur l'hypothèse que les observations proches auront des valeurs cibles similaires ou bien quasi-identiques.

Pour prédire le retard d'un nouveau vol x :

- i. Calcul la distance entre x et les autres données :

$$d(x, x') = \left(\sum (x_i - x'_i)^2 \right)^{1/2}$$

- ii. Trouver les voisins les plus proches
- iii. Obtenir la prédiction en utilisant la moyenne

$$\hat{y} = \frac{1}{K} \sum_{i=1}^K y_i$$

Cette méthode est particulièrement utile pour détecter les regroupements locaux

de potabilité. Cependant, elle est coûteuse en calcul lors de l'inférence et très sensible au « fléau de la dimensionnalité »

2. Multilayer Perceptron (MLP)

Le MLP constitue une architecture de réseau neuronal artificiel capable de modéliser des relations fortement non linéaires, en combinant plusieurs couches de neurones transformant progressivement l'espace des données.

Un MLP comporte :une couche d'entrée, une ou plusieurs couches

cachées, une couche de sortie.

La formule générale :

$$\hat{y} = f(W_2 \cdot \sigma(W_1 x + b_1) + b_2)$$

Où la matrice W sont les poids et b les biais

MLP est un modèle très puissant pour capturer des relations complexes et non linéaires dans les données. Ils donnent souvent d'excellents résultats sur des problèmes difficiles, comme la prédiction des retards d'avion. En revanche, ils demandent une bonne préparation des données (surtout la normalisation) et peuvent facilement surapprendre .

3. Random Forest

Le Random Forest repose sur un ensemble d'arbres de décision entraînés de manière aléatoire. Chaque arbre utilise un sous-échantillon différent des données ainsi qu'un sous-ensemble de variables, ce qui permet de réduire la corrélation entre les arbres. Cette diversité améliore la stabilité du modèle et diminue la variance des prédictions.

La prédiction finale est la moyenne des prédictions de chaque arbre seule:

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T h_t(x)$$

4. Régression Logistique

La Régression Logistique a été employée non seulement comme classifieur, mais comme référence diagnostique pour évaluer la séparabilité linéaire de l'espace des caractéristiques. Fondamentalement, la Régression Logistique postule que le logarithme des cotes de retard peut être modélisé comme une combinaison linéaire des variables d'entrée. Nous avons utilisé le solveur 'liblinear', optimisé pour les ensembles de données de taille modérée. La probabilité qu'un vol appartienne à la classe positive (Retardé) est transformée via la fonction sigmoïde :

$$P(y = 1|\mathbf{x}) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}}$$

Bien que très interprétable, permettant d'examiner le poids direct de caractéristiques comme le retard au départ, la Régression Logistique montre ses limites dans les contextes où la frontière de décision est non-linéaire. Par exemple, si les retards dépendent de combinaisons complexes entre la météo et l'heure, un modèle linéaire ne peut capturer ces interactions sans une ingénierie de caractéristiques avancée.

5. Support Vector Machine (SVM)

Le SVM est un classifieur à marge maximale qui cherche à trouver l'hyperplan optimal séparant les vols à l'heure des vols retardés avec la marge la plus large possible. Contrairement à la RL, le SVM peut être étendu à des frontières non-linéaires via l'utilisation de fonctions noyau. Nous avons utilisé un noyau linéaire pour sa rapidité et son interprétabilité géométrique. L'objectif est de minimiser :

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \max(0, 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b))$$

où C contrôle le compromis entre la largeur de la marge et la tolérance aux erreurs de classification. Ce modèle est particulièrement robuste aux données modérément dimensionnées et aux cas où les classes sont presque linéairement séparables.

IV. EXPERIMENTAL RESULTS

1. Régression

a) Séparation des données :

Pour tester nos modèles , nous avons séparé notre dataset en deux parties 80% train et 20% test .

b) Choix des hyper paramètres :

L'optimisation des hyperparamètres des modèles (KNN, MLP, Random Forest) est réalisée grâce à la méthode RandomizedSearchCV. Cette approche d'échantillonnage aléatoire est choisie pour explorer l'efficacité d'un vaste espace de recherche de configurations sans recourir à un balayage exhaustif. Elle permet d'explorer rapidement les paramètres performants, même sur un grand nombre de données.

L'efficacité de RandomizedSearchCV est renforcée par la validation croisée. Ce couplage est essentiel pour garantir la robustesse des performances estimées et assurer la pertinence des sélections d'hyperparamètres, prévenant ainsi les risques de surapprentissage sur les données spécifiques d'entraînement.

c) Comparaison des modèles :

Le tableau I résume les performances sur l'ensemble de test classées du meilleur résultat au moins performant :

Modèle	MAE (min)	RMSE (min)	R²
MLP	—	14.29	0.894
Random Forest	—	14.38	0.893
Régression Linéaire	9.72	14.43	0.892
KNN	—	16.90	0.852

C. Interprétation des métriques :

1) Régression Linéaire :

Malgré sa simplicité ,or le modèle donne de bons résultats, il explique 89% de la variance avec une erreur moyenne de 10 min .

2) KNN

Performances inférieures au 85.2% , avec un cout très élevé ce qui montre que ce type de modele n'est pas applicables à notre dataset .

3) MLP

Le réseau neuronal offre la **meilleure généralisation** :

$R^2 = 0.894$, $RMSE = 14.29$ min, avec une architecture optimale : (50,50), activation ReLU.

Donc ce modele capture efficacement des interactions complexes entre les variables.

4) Random Forest — Meilleur Compromis

Donne des résultats presque aussi performants que le MLP, c'est un model plus stable , robuste aux outliers et plus rapide au niveau d'entraînement , il est préférable de l'utiliser pour les systèmes temps réels .

Sélection du Modèle Final

On observe que les modèles linéaires restent étonnamment efficaces malgré leur simplicité. Les modèles non linéaires, comme le MLP ou le Random Forest, font mieux que les baselines de façon constante. En revanche, le KNN montre ses limites ici, surtout à cause de la taille et de la dimensionnalité des données aériennes. Dans l'ensemble, ces résultats confirment que

les retards ne suivent pas des règles simples : ils dépendent de façon complexe des interactions entre météo, infrastructures aéroportuaires et planning des vols.

2. Classification

La classification, consiste à prédire à quelle catégorie appartient un échantillon en se basant sur ses caractéristiques. Ici, le défi consiste à construire un modèle qui classe les vols en deux groupes : ceux qui arrivent à l'heure (classe 0) et ceux qui accusent du retard (classe 1). On s'appuie sur la variable cible delay_15min, qui signale si un vol a au moins 15 minutes de retard à l'arrivée. Les variables explicatives, elles, proviennent d'un ensemble de données complet sur les vols.

Les performances des modèles ont été évaluées à l'aide des métriques suivantes : accuracy, balanced accuracy, precision, recall, le score F1 et l'aire sous la courbe ROC (ROC-AUC). Ces métriques permettent de juger respectivement de la performance globale, de la fiabilité des prédictions positives, de la capacité à détecter tous les retards, de l'équilibre entre ces deux dernières, et de la capacité discriminative du modèle.

Modele	Accuracy	Balanced Accuracy	F1	ROC - AUC	Precision
LOGISTIC REGRESSION	0.890	0.868	0.810	0.926	0.805
SVM	0.894	0.868	0.815	0.926	0.824
RANDOM FOREST	0.902	0.861	0.818	0.932	0.883
MLP	0.903	0.856	0.815	0.929	0.899

Analyse des Résultats

On constate que Réseau de Neurones obtient la meilleure exactitude (0.903), suivi par Random Forest (0.902). Tous les modèles dépassent 89 % d'exactitude, ce qui confirme la qualité des variables utilisées pour la classification, le Réseau de Neurones offre la meilleure précision (0.899), suivi du Random Forest (0.883). Lorsqu'ils prédisent un retard, leur décision est donc plus fiable, avec moins de fausses alertes que les modèles linéaires (Logistique : 0.805, SVM : 0.824). On remarque aussi que Random Forest obtient le meilleur F1-Score (0.818), montrant le compromis le plus équilibré entre détection des retards et fiabilité des prédictions. Le SVM et le Réseau de Neurones obtiennent des scores proches (0.815).

Tous les modèles présentent une AUC supérieure à 0.92, signe d'une excellente capacité à distinguer « retardé » et « à l'heure ». Le Random Forest (0.932) et le Réseau de Neurones (0.929) obtiennent les meilleurs scores.

Sélection du Modèle Final

Bien que plusieurs modèles présentent des performances comparables, le **Random Forest** est retenu comme modèle final pour ce projet. Cette décision est motivée par plusieurs facteurs :

Performance équilibrée : Il obtient le meilleur F1-Score (0.818) et le meilleur AUC-ROC (0.932), indiquant un excellent équilibre entre détection fiable et exhaustive des retards.

Robustesse opérationnelle : Contrairement au Réseau de Neurones qui offre une précision légèrement supérieure (0.899 vs 0.883) mais au prix d'un recall nettement inférieur (0.746 vs 0.762), le Random Forest fournit un compromis plus adapté aux besoins métier où manquer des retards réels peut avoir un coût opérationnel important.

Interprétabilité relative : Bien que moins interprétable que les modèles linéaires, le Random Forest permet d'extraire l'importance des features, offrant des insights actionnables pour les décideurs.

Discussion

Les résultats montrent que les modèles présentent de bonnes performances, confirmant la fiabilité des données pour la préparation des données originales. Les modèles linéaires restent efficaces, ce qui indique que certains retards sont prolongés par des relations directes, et non par le retard initial.

Il est à noter que les modèles non linéaires, spécifiques aux MLP et aux forêts aléatoires, offrent de meilleures performances. Leur capacité à capturer des interactions complexes garantit que les réactions ne peuvent se réduire à une simple structure linéaire.

L'analyse des variables prend en compte l'influence importante du futur, notamment des facteurs contextuels tels que les conditions météorologiques et la congestion, qui contribuent aux variations observées.

Conclusion :

Dans cet article, nous avons exploré le problème de la récupération des retards d'autrui avec une approximation complète, la régression du chronomètre pour le nombre de minutes de retard, et la classification des volumes tels que le temps ou les retards, afin de comparer nos téléphones. Plus les modèles avec applications supervisées, les résultats liés à la forêt aléatoire obtiennent de meilleures performances en classification, confirmant la capacité du modèle à gérer les interactions non linéaires avec d'autres facteurs. Parallèlement, l'ensemble de neurones MLP est plus efficace pour la régression, grâce à sa capacité à capturer des relations complexes entre les variables.

Ces résultats sont conditionnés par le développement des applications : la classification permet une détection des risques, tandis que la régression fournit une estimation précise du retard, utile pour l'allocation des ressources et la communication après les passagers. Toutefois, l'introduction de limites à l'utilisation des données historiques et l'absence de certaines variables opérationnelles constituent des limitations. Les travaux futurs porteront sur l'intégration de données à température réelle et l'exploration de modèles et de séquences adaptés aux données temporelles.

Source :

[1] : https://www.researchgate.net/publication/355861706_Flight_Delay_Prediction_Using_Machine_Learning_Algorithms

[2] : <https://www.sciencedirect.com/science/article/pii/S0968090X19307569>

[3] <https://data.mendeley.com/datasets/j3z5bm7496/1>